

Оптимизация работы AI-ассистента для бизнеса

Контекст

Компания СберБизнесСофт вывела на рынок продукт «AI-ассистент для бизнеса» (далее «ассистент» или «чат-бот»), который представляет собой чат-бота с использованием технологии RAG, т.е. поисковик, улучшенный и дополненный контекстом из файлов и баз знаний. Более подробно почитать о RAG подходе можно по ссылке 1 и ссылке 2. Клиент (компания заказчик, владельцы бизнеса) может загрузить в ассистента документы о компании или отдельных процессах, и при обращении конечных пользователей (запрос с уточнением информации о бизнесе, вопрос о деталях и нюансах своего заказа и пр.) ассистент сможет отвечать на вопросы с учётом содержания документа. В данном задании клиентом является компания, занимающаяся отельным бизнесом.

Задача

Разработать универсальный промпт, который бы оценивал точность и адекватность ответа ассистента по вопросу и документу. И предложить коммуникацию про саму функцию для владельцев отелей, то есть рассказать и убедить их попробовать ей воспользоваться путём разработки рекламных материалов на целевую аудиторию владельцев.

В первый день необходимо сдать артефакты решения путём загрузки информации в форму, во второй — представить результаты работы в виде презентации, шаблон которой будет представлен экспертами.

Артефакты решения, которые вашей команде необходимо сдать до 19:00 в первый день

1. Описание продуктового решения:

- * Алгоритм, описывающий, как промпт будет работать, включая логику использования параметров
- * Описание, как предлагаемое решение минимизирует усилия тестировщика или аналитика, который вместо ручной оценки ответа сможет доверить оценку LLM
- * Пояснение, как выбранные переменные влияют на результат и почему они были выбраны

2. Сформированный промпт и набор переменных:

- * Основной текст промпта, в который уже встроены переменные
- * Список переменных с пояснением их значений (вопрос клиента, ответ RAG-системы, фрагменты документа и пр.)
- * Примеры использования промпта с различными значениями переменных и пояснением, как значения влияют на ответ модели
- * Указание модели, в которой велась работа с промптами (предпочтителен Gigachat, но готовы рассмотреть и решения других моделей)

3. Тестовые примеры результатов:

- * Минимум три теста с конкретными параметрами, демонстрирующие разные случаи (например, ответы на разные вопросы клиентов)
- * Результаты тестов: примеры ответов модели на каждый вариант промпта, которые показывают, насколько релевантен и полезен полученный промпт для решения кейса

Артефакты решения, которые ваша команда представляет экспертам на очных защитах во второй день

- * Презентация, составленная по шаблону, который будет презентован вам вместе с критериями для очных защит в конце второго дня

Дополнительная информация к кейсу

Ожидаемый формат работы ассистента с пользователями выглядит следующим образом:

1. Чат-бот настроен на сайте отеля, чтобы отвечать на часто-задаваемые вопросы (faq) пользователей. Пример: Где находится ваш отель.
2. В систему также загружен документ клиента (приложен к чату), в котором содержится дополнительная информация об отеле. На основании этого документа чат-бот может также давать ответы пользователям.
3. Ответ генерируется ботом на основе информации из документа и вопроса пользователя. Пример: У вас есть номера с балконом? Ответ: Да, у нас есть отдельная категория номеров «Комфорт с балконом».

Полезные ссылки

- [Список вопросов \(с эталонными ответами ассистента\)](#)
- [Документ с описанием отеля](#)

В теле промпта в качестве параметров выступают:

- Вопрос пользователя чат-боту,
 - Ответ чат-бота,
 - Разрешено расширять список параметров при необходимости.
-

Дополнительная информация к кейсу

Итогом промпта должна стать оценка точности ответа по шкале от 0 до 5, а также оценка адекватности ответа по шкале 0 или 1. То есть оценки 5 и 1 — это самый точный и адекватный ответ. Текстовое обоснование оценки обязательным не является, но оно поможет вам в улучшении качества промпта. Для проверки качества работы промпта, в списке вопросов и ответов также есть gold-ответ, т.е. ответ, который заказчик считает идеальным на поставленный вопрос. Целевые ответы даны исключительно справочно для понимания критериев оценки. Использование эталонных ответов в промпте запрещено. Отдельно учитывается универсальность промпта в части приложенных документов, списка вопросов пользователей и отрасли бизнеса.

Пример коммуникационных материалов: сгенерировать поздравление клиентам от имени Сбер Бизнес Софт в виде открытки и сопроводительного текста с пожеланием внедрить RAG-систему и «убеждением ею воспользоваться».